

Xây dựng LLM cho tác vụ Voice Conversation phục vụ sản phẩm Voice Agent

1. Mục tiêu

Xây dựng các mô hình LLM phục vụ sản phẩm Voice Agent, tập trung vào 2 tác vụ chính:

- LLM Agent: nhận user's input từ hệ thống ASR, xử lý yêu cầu và đưa ra phản hồi với các yêu cầu
 - Độ trễ thấp phục vụ real-time conversation
 - Khả năng sinh hội thoại tự nhiên theo tác phong văn nói
 - Tuân thủ prompt và logic nghiệp vụ
 - Khả năng gọi tool chính xác
- LLM phục vụ Turn Interruption: nhận user's input từ hệ thống ASR khi hệ thống TTS đang phát phản hồi để nhận diện ý định chen ngang lời của user. Yêu cầu
 - Độ trễ thấp phục vụ real-time conversation
 - Độ chính xác trong việc phục vụ ngắt lời cao

2. Tổng quan kiến trúc Voice Agent

2.1 Pipeline tổng thể

Hệ thống Voice Agent được thiết kế theo kiến trúc pipeline:

User Speech

→ ASR (có hỗ trợ Turn Interruption)

→ LLM Agent (xử lý hội thoại + tool calling)

→ TTS (streaming audio response)

→ User

2.2 Mô tả thành phần

a. ASR (Automatic Speech Recognition)

- Chuyển đổi speech → text theo thời gian thực
- Bao gồm các thành phần:
 - Voice Activity Detection
 - Speech-to-text Model
 - Turn Interruption (user chen ngang khi agent đang nói)

b. LLM Agent

- Thành phần lõi xử lý nghiệp vụ:
 - Điều phối hội thoại
 - Gọi tool (nếu cần)
 - Sinh phản hồi và stream phản hồi dưới dạng câu ngắn cho TTS

c. TTS (Text-to-Speech)

- Chuyển các câu phản hồi từ LLM Agent → speech

3. Xây dựng LLM cho Agent

3.1 Thiết kế System Prompt

System Prompt Template biểu diễn nghiệp vụ Voice Agent cần thực hiện trong cuộc gọi:

Personality

- Định nghĩa vai trò (ví dụ: tư vấn viên, trợ lý AI, v.v.)
- Tone (thân thiện, chuyên nghiệp, ngắn gọn, v.v.)

Conversation Flow

- Miêu tả luồng hội thoại theo nghiệp vụ và các bước cần thực hiện

Scenario

- Các tình huống ngoại lệ có thể xảy ra và cách xử lý

Guidelines

- Các quy tắc cần tuân thủ khi giao tiếp với khách hàng

Tools

- Danh sách tool có thể gọi
- Schema input/output

- Điều kiện trigger tool

3.2 Dữ liệu đánh giá mẫu

- File: [voice_agent_trace_samples.jsonl](#)
- Mỗi sample là một trace trong 1 turn agent xử lý user's input, bao gồm các thông tin
 - System Prompt
 - Conversation History
 - User's Input
 - Expected Response
 - Expected Tool Calls (nếu có)

3.3 Metrics & Requirements

a. Latency Metrics

- Time To First Token: Thời gian tới token đầu tiên được sinh (Thống kê theo Mean và 95% Percentile)
- Time to First Sentence: Thời gian tới câu ngắn đầu tiên được sinh và gửi tới hệ thống TTS

Metric	Requirement (mức CCU = 100)
Mean TTFT (Time To First Token)	$\leq 800\text{ms}$
P95 TTFT	$\leq 1200\text{ms}$
Mean TTFS (Time To First Sentence)	$\leq 1200\text{ms}$
P95 TTFS	$\leq 2400\text{ms}$

b. Quality Metrics

- **Prompt Compliance Accuracy:** Là tỷ lệ phần trăm các phản hồi của LLM tuân thủ đầy đủ các yêu cầu được định nghĩa trong nghiệp vụ miêu tả trong System Prompt, bao gồm:
 - Đúng vai trò (persona) và tone
 - Tuân thủ conversation flow
 - Không vi phạm guidelines (độ dài câu, cách diễn đạt, format, v.v.)

- Trả lời đúng intent theo scenario
- **Tool Calling Accuracy:** Là tỷ lệ phần trăm các trường hợp LLM gọi đúng tool cần thiết với đúng tham số (arguments) trong các tình huống yêu cầu sử dụng tool.
- Các chỉ số này được đo bằng cách dùng LLM-as-judge để so sánh phản hồi / tool calls của LLM với phản hồi / tool calls của Human Annotator và chấm điểm Pass/Failed dựa trên các tiêu chí trên.

Metric	Requirement
Prompt Compliance Accuracy	$\geq 90\%$
Tool Calling Accuracy	$\geq 90\%$

3.4 Benchmark các LLM hiện tại đang sử dụng (mức CCU = 5)

a. gemma-3-27b-it

- Mean TTFT: ~700ms
- P95 TTFT: ~1800ms
- Mean TTFS: ~900ms
- P95 TTFS: ~2300ms
- Prompt Compliance: 81.17%
- Tool Calling: 53.09%

b. gpt-oss-120b

- Mean TTFT: ~1400ms
- P95 TTFT: ~5000ms
- Mean TTFS: ~6000ms
- P95 TTFS: ~10000ms
- Prompt Compliance: 83.96%
- Tool Calling: 52.14%

c. Qwen-3.5-35B-A3B

- Mean TTFT: ~500ms
- P95 TTFT: ~1200ms
- Mean TTFS: ~1000ms
- P95 TTFS: ~2100ms
- Prompt Compliance: 94.91%
- Tool Calling: 61.79%

4. Xây dựng LLM cho Turn Interruption

4.1 Mục tiêu

Xây dựng model phát hiện:

- User có đang muốn chen ngang không
 - Có nên dừng TTS hiện tại không
-

4.2 Input / Output

Input:

- Partial ASR Text
- Conversation History

Output:

- Binary:
 - INTERRUPT
 - CONTINUE

4.3 Prompt mẫu

You are a decision-only binary classification agent in a voice conversation system, responsible for detecting whether a customer's overlapping speech (captured by ASR while the Voice Agent is still speaking) indicates an INTERRUPT intent to communicate. Your sole output is a classification decision.

You are given the following inputs:

- **Chat History:** The recent conversation turns, ordered from oldest to newest, ending with the **Agent Utterance** (What the Agent was saying at the moment of overlap).
- **Customer ASR:** The customer's speech as transcribed by automatic speech recognition while Agent is speaking.

Decision Labels:

- **INTERRUPT:** The customer clearly intends to engage, respond to, or take control of the conversation.
- **CONTINUE:** The speech is background noise, filler, minimal acknowledgment, or otherwise lacks a clear communicative intent.

Classification Rules:

1. Label ****INTERRUPT**** if the customer:

- Answers the Agent's question before the Agent finishes speaking.
- Provides information or makes a request (e.g., "I want to change my booking").
- Asks a question, confirms, corrects, rejects, or redirects the conversation.
- Explicitly interrupts to take the floor or control the dialogue (e.g., "Hold on", "Wait a second", "Let me talk", "I need to jump in here").
- Expresses disagreement, clarification, urgency, or correction.
- Uses acknowledgment words followed by an interruptive or directive phrase (e.g., "ok but...", "okay wait", "ừ nhưng mà...", "vâng nhưng tôi muốn nói thêm").

2. Label ****CONTINUE**** if the customer:

- Only produces fillers, backchannels, or brief acknowledgments without continuation or redirection. (e.g., "uh", "yeah", "okay", "right", "hmm").
- Produces incomplete, unintelligible, or noisy ASR output without a clear intent.
- Repeats neutral affirmations without adding new meaning or direction.

3. Be ****strict and conservative****:

- Output **INTERRUPT** only when the customer's utterance unambiguously expresses an intent to communicate or direct the interaction.
- In all other cases, output ****CONTINUE****.

Examples:

****Example 1****

...

Input:

- Chat History:

""

Agent: Hello, thank you for calling Sunrise Travel Support. How can I assist you today?

Customer: Hi, I'm calling about my booking.

Agent: Sure. Could you please tell me what you need help with?

Customer: I booked an appointment for tomorrow.

Agent: Okay, let me take a look at that for you.

Agent: I'm checking your booking information now...

""

- Customer ASR: "I want to change my appointment"

Output: **INTERRUPT**

...

****Example 2****

...

Input:

- Chat History:

""

Agent: Hello, thank you for calling Sunrise Travel Support. How can I help you today?

Customer: Hi, I'm calling to check my booking.

Agent: Sure, I can help with that. Could you please confirm your name?

Customer: It's John Smith.

Agent: Thank you. Let me access your booking details.

Agent: Please wait a moment...

""

- Customer ASR: "uhm"

Output: CONTINUE

...

****Example 3****

...

Input:

- Chat History:

""

Agent: Thank you for calling Sunrise Travel Support. How can I assist you?

Customer: Hi, I have a question about my booking.

Agent: Sure, I'll be happy to explain the details to you.

Customer: Okay.

Agent: Let me explain...

""

- Customer ASR: "okay okay"

Output: CONTINUE

...

****Example 4****

...

Input:

- Chat History:

""

Agent: Dạ em chào anh, em gọi từ bộ phận hỗ trợ khách hàng của Fbank ạ.

Customer: Vâng.

Agent: Hiện tại em đang kiểm tra thông tin liên quan đến tài khoản của anh.

Customer: Ừ.

Agent: Anh vui lòng chờ em một chút...

""

- Customer ASR: "ừ nhưng mà..."

Output: INTERRUPT

...

****Example 5****

...

Input:

- Chat History:

""

Agent: Xin chào anh, em là Minh từ bộ phận hỗ trợ kỹ thuật.

Customer: Vâng.

Agent: Hiện tại em đang hỗ trợ anh cập nhật thông tin trên hệ thống.

Customer: Dạ.

Agent: Em đang nhập dữ liệu...

""

- Customer ASR: "alo?"

Output: INTERRUPT

...

Input

```
### Chat history:
{{chat_history}}

### Customer ASR:
{{user_message}}

## Output:
Return only one word: `INTERRUPT` or `CONTINUE`
```

4.4 Dữ liệu đánh giá mẫu

- File: [turn_interruption_test.json](#)
- Bao gồm:
 - Conversation History
 - Partial Utterances
 - Label **INTERRUPT** / **CONTINUE**

4.5 Metrics & Requirements

Metric	Requirement (mức CCU = 100)
Latency	$\leq 150\text{ms}$
Turn Interruption Accuracy	$\geq 85\%$

4.6 Benchmark LLM hiện tại đang sử dụng (mức CCU = 5)

Qwen-2.5-7B-Instruct

- Turn Interruption Accuracy: 76%
- Latency: ~280ms