

FCI · VOICE AI AGENT

Từ module của q-omni đến giá trị khách hàng

Customer-first · bài toán và hướng cải tiến Voice AI Agent

Lab QASI Multimodal (q-omni) × FCI · 2026-07-06

Chuỗi giá trị customer-first — 4 lớp

q-omni — sản xuất các module của AI-Agent

khách hàng → FCI

FCI — lắp module thành AI-Agent hoàn chỉnh

khách hàng → Doanh nghiệp

Doanh nghiệp — tăng tỷ lệ chuyển đổi, giảm chi phí trong domain

khách hàng → Người dùng cuối

Người dùng cuối — được phục vụ tốt và nhanh hơn

Module của q-omni chỉ thực sự có giá trị khi góp phần **tăng tỷ lệ chuyển đổi** cho doanh nghiệp

Hai key-point cần cải tiến của Voice Agent

Key-point #1

Turn-detection

Module bắt nhịp lượt lời: khách nói xong chưa, có chen ngang không.

- Là module bị **noise** ảnh hưởng nặng nhất.
- Sai thì bot cắt lời hoặc đáp trề, khách bỏ máy.
- Context: kênh 8kHz, người xung quanh, echo.

Key-point #2

Agent-reasoning

Bộ não chọn bước tiếp theo, gọi tool, giữ đúng mục tiêu.

- Là module dễ **làm sai lệch luồng hội thoại**.
- Sai thì chọn nhầm bước, bịa số, lạc mục tiêu, không chốt được việc.
- Context: oriented conversation (not open-end conversation).

Chọn đúng key-point để dồn nguồn lực cải tiến trước.

Oriented vs Open-end — conversation

Open-end

- Không có mục tiêu nghiệp vụ cố định.
- LLM tự do phản hồi theo ngữ cảnh.
- Dễ làm, nhưng khó kiểm soát chuyển đổi.

Oriented

- Mỗi bước đẩy hội thoại về mục tiêu nghiệp vụ.
- Phải giữ mục tiêu, kiểm soát từng bước.
- Gọi tool đúng lúc, đúng dữ liệu.

Tỷ lệ chuyển đổi sinh ra trong hội thoại **oriented**, không phải open-end.

PHẦN 3

Hướng giải — xử lý phân tầng theo chi phí

Tình huống dễ giải ở tầng rẻ; chỉ tình huống khó mới đẩy lên model đắt.

Hệ thống FCI đang chạy baseline — Q-omni sẽ nghiên cứu các giải pháp phức tạp tiếp theo

Turn-detection — xử lý phân tầng trên nền FCI

Tận dụng mọi nguồn dữ liệu

- voice-audio (giọng khách)
- env-audio (nhiều nền)
- context hội thoại (text)
- node đang đứng trong FSM

Tầng 0 · hệ thống FCI đang chạy

noise-detector · rule-based guardrail · rẽ nhánh tình huống ngoại lệ

Tầng rẻ · classify model nhỏ

Tầng giữa · zero-shot model

Tầng đắt · LLM có ngữ cảnh

q-omni ghép thêm **3 tầng ML** lên trên Tầng 0 của FCI, chỉ nhận các tình huống khó hoặc ngoại lệ do Tầng 0 chuyển lên.

Agent-reasoning — từ prompt nguyên khối sang flow-management

hiện tại

FSM-based-LLM

- Một prompt nguyên khối chứa cả kịch bản và mọi tool.
- LLM dễ lạc mục tiêu, chọn nhầm tool.
- Khó kiểm soát và khó debug.

hướng đi

Flow-management (Pipecat)

- Chia kịch bản thành nhiều node, mỗi bước một mục tiêu.
- Giới hạn tool theo từng node.
- Giữ dữ liệu bằng shared state, hết phình prompt.

Đây là **bài toán ghép module đúng kiến trúc**, không phải cứ đổi sang model lớn hơn là xong.

Pipecat là gì

Framework open-source để xây voice-agent realtime. Ý tưởng lõi: tách 2 lớp độc lập.

Lớp A

Data pipeline

Cơ chế vận hành — cách dữ liệu chạy qua hệ thống.

- Luồng: Transport → STT → Context → LLM → TTS.
- Đổi provider (STT, TTS...) không đụng nghiệp vụ.

Lớp B

Flows

Logic hội thoại — cuộc gọi đi qua những bước nào.

- Graph các node, mỗi node một bước có mục tiêu.
- Điều khiển prompt và tool của LLM ngay giữa cuộc gọi.

Hai lớp tách biệt: đổi nghiệp vụ (Lớp B) không đụng audio (Lớp A), và ngược lại.

Pipecat — hai lớp phối hợp thế nào


Lớp A · Data pipeline — dữ liệu chạy tuần tự qua các module:



↑ **Lớp B · Flows** — dùng graph node để đổi prompt và tool của LLM theo từng bước

Lớp B chỉ tác động vào **LLM** (quyết mỗi lúc LLM thấy prompt và tool nào), không đụng phần audio.

Lớp B — cuộc gọi oriented thành FSM (ví dụ đòi nợ)



Mỗi node xử lý đúng một tác vụ -> LLM gọi tool, xử lý -> trả kết quả -> chuyển sang node kế tiếp khi hoàn thành tác vụ đó.

Cấu trúc hóa hội thoại **open-end** → **oriented**.

Bên trong một node

 **Task goal**
mục tiêu riêng của bước

 **Hook** trước / sau
thoại chờ, gọi API, kết thúc

1 NODE
= 1 bước có mục tiêu

 **Tool riêng**
chỉ mở tool bước này cần

 **Function**
trả kết quả và node kế tiếp

 **Shared state** — giữ dữ liệu xuyên suốt mọi node

FSM giúp gì cho guardrail và turn-detection

Chia hội thoại thành node không chỉ giúp reasoning — nó thu hẹp ngữ cảnh cho cả guardrail và turn-detection.

Guardrail

Khoanh vùng nội dung chặt hơn

- Node biết bước hiện tại đang cần thông tin gì.
- Loại ngay câu thoại lan man, lạc tác vụ của node.
- Gom input của user về đúng chủ đề bước đó.

Turn-detection

End-of-turn và barge-in có cơ sở hơn

- EOU: chờ user trả lời đủ thông tin node cần mới chốt lượt.
- Node hỏi gọn, không dồn nhiều thông tin một lúc → user ít ngắt lời.
- Khi user ngắt: đoán thông tin theo context hẹp của node → chính xác hơn.

Node càng hẹp → guardrail và turn-detection càng có ngữ cảnh để quyết đúng.

Turn-detection — bản đồ các bài toán con

Tiền xử lý âm thanh — làm sạch tín hiệu trước khi quyết lượt lời:

VAD
có tiếng nói không

Target-speaker
đúng giọng khách, khử echo

Background-noise
lọc tiếng nền

▼ quyết theo trạng thái bot

bot đang im

EOU · end-of-turn

- User đã nói xong chưa?
- Quyết thời điểm bot bắt đầu trả lời.

bot đang nói

Barge-in · chen ngang

- Có nên dừng TTS không?
- **Backchannel**: "dạ/vâng/ừ" là đệm (nói tiếp) hay ý định ngắt thật (dừng).

Đã khảo sát kỹ ở **layer 05_turn_interruption** — taxonomy ngắt lời + phân tầng barge-in (deck kỹ thuật T6-T8).

Cách q-omni chủ động join sâu cùng FCI — đi lên từ data

Hệ thống hóa cách làm việc, bắt đầu từ dữ liệu — không nhảy ngay vào bài toán phức tạp.

1 · Hiểu dữ liệu

join và query đúng dữ liệu cần từ FCI.

2 · Data analysis

chủ động bóc tách, tìm pattern và issue.

3 · Bộ monitor chất lượng

chuẩn hóa thành công cụ giám sát hội thoại.

4 · Nắm data + issue liên tục

nền vững rồi mới tính bài toán phức tạp hơn.

Chủ động nắm chắc **data và issue** một cách liên tục trước; việc phức tạp hơn tính sau.

4 nội dung muốn thống nhất với FCI

1 · Chuỗi giá trị

Ranh giới bàn giao giữa module (q-omni) và AI-Agent tích hợp (FCI) ở đâu.

2 · Thứ tự ưu tiên

Cải tiến turn-detection (noise) hay agent-reasoning (oriented) trước.

3 · Kiến trúc reasoning

FCI đã theo flow-management chưa, hay còn prompt nguyên khối.

4 · Truy cập dữ liệu

Mở data để q-omni join, query và dựng monitor chất lượng.

Cảm ơn và thảo luận

Nguyên tắc cốt lõi: module của q-omni được đo bằng tỷ lệ chuyển đổi thực tế của doanh nghiệp.